

Matriz de Optimizacion de Costos | Parte 1: que modelo para cada tarea

Criterio de seleccion por tipo de carga, no por preferencia de proveedor | precios verificados el 18/08/2026

El principio que ordena esta matriz: el modelo mas caro no es el mejor, es el mejor para tareas que lo justifiquen. Clasificar un mensaje de 80 palabras y elegir una de tres categorias no requiere razonamiento de frontera. Pagar por capacidad que la tarea no usa es el error de costos mas comun en automatizacion.

TAREA	MODELO ELEGIDO	PRECIO IN/OUT	POR QUE ESE	ALTERNATIVA DESCARTADA	JUSTIFICACION DE LA DECISION
Clasificar y redactar la respuesta al lead (tarea principal del sistema)	Gemini 2.5 Flash-Lite	USD 0,10 / 0,40 por millon	Tarea acotada: leer 80 palabras, elegir 1 de 3 etiquetas y redactar 150 con datos ya provistos.	GPT-5.6 Sol (5,00 / 30,00)	El modelo de frontera cuesta 64 veces mas en salida y no mejora una clasificacion de tres categorias. La calidad aca la determina lo claro que sea el prompt y lo confiable que sea el catalogo, no el tamano del modelo.
Lectura densa: analizar un pliego, contrato o brief largo de un cliente	Claude Sonnet 5	USD 2,00 / 10,00 por millon	Ventana de contexto amplia sin recargo y mejor sostenimiento del hilo en textos largos.	Gemini Flash-Lite	Aca si se justifica pagar mas: un error de interpretacion en un pliego cuesta mas que la diferencia de tokens. Precio promocional vigente hasta el 31/08/2026; despues pasa a 3,00 / 15,00.
Procesos masivos sin urgencia: reclasificar el historico, reportes nocturnos	Batch API del proveedor	50% del precio estandar	Se acepta demora de hasta 24 horas a cambio de la mitad del costo.	Llamadas sincronicas una por una	Si nadie espera la respuesta en pantalla, pagar por inmediatez es tirar plata. Aplica a reprocesos, nunca al flujo en vivo donde el lead espera contestacion.
Decisiones deterministas: detectar noreply, validar que el email exista	Filtros nativos de Make	0 tokens	Es una comparacion de texto. No hay ambigüedad que interpretar.	Preguntarle al modelo	El error mas caro y mas frecuente del principiante: usar un LLM donde alcanza un IF. Nuestro filtro anti-loop resuelve esto antes de gastar un solo token ni una sola operacion de IA.
Contexto repetido: el catalogo de servicios que viaja en cada prompt	Prompt caching	10% del precio de entrada	El catalogo es identico en todas las llamadas; se paga completo una sola vez.	Reenviar el catalogo entero	Con volumen alto, cachear el bloque fijo recorta hasta 90% del costo de entrada. Con el volumen actual el ahorro es marginal, pero es la primera palanca a activar al escalar.

Precios de lista por millon de tokens, tarifa estandar de API directa, relevados el 18/08/2026. Los proveedores ajustan tarifas con frecuencia: esta matriz documenta el criterio de decision, que sigue siendo valido aunque los numeros cambien.

Matriz de Optimizacion de Costos | Parte 2: costo real por lead procesado

Calculo sobre consumo medido en ejecuciones reales: 7 creditos de Make y unos 1.050 tokens por lead

Consumo de tokens por lead

Instrucciones del prompt (rol, criterios, formato)	~ 260 tokens
Catalogo de servicios recuperado de Airtable	~ 350 tokens
Consulta del lead (nombre, empresa, mensaje)	~ 190 tokens
TOTAL ENTRADA	~ 800 tokens
Respuesta JSON: categoria, score, justificacion, borrador	~ 250 tokens
TOTAL SALIDA	~ 250 tokens

Costo de IA por lead: USD 0,00018 (menos de dos centesimas de centavo)

El mismo lead, procesado con distintos modelos

Proyeccion sobre un volumen de 500 leads mensuales, mismo prompt y misma salida.

MODELO	POR LEAD	500 LEADS	SOBRECOSTO
Gemini 2.5 Flash-Lite (el elegido)	USD 0,00018	USD 0,09	-
Gemini 3.5 Flash-Lite	USD 0,00087	USD 0,44	5 x
Claude Sonnet 5	USD 0,00410	USD 2,05	23 x
Claude Opus 4.8	USD 0,01025	USD 5,13	57 x
GPT-5.6 Sol	USD 0,01150	USD 5,75	64 x

Costo total del ecosistema | donde esta la plata de verdad

El hallazgo mas util del ejercicio: el gasto no esta en la IA. A este volumen, el modelo cuesta centavos y la plataforma de orquestacion cuesta dolares.

COMPONENTE	PLAN	COSTO MENSUAL	LIMITE DEL PLAN	CUANDO OBLIGA A SUBIR DE ESCALON
Make (orquestacion)	Core	USD 9 a 12	10.000 creditos	A 7 creditos por lead, el plan Core cubre unos 1.400 leads por mes. El plan Free (1.000 creditos) solo alcanza para 142.
Google Gemini (IA)	Free tier	USD 0	Cuota diaria de requests	El free tier cubre el volumen de un estudio chico. Pasar a pago cuesta 0,09 dolares cada 500 leads.
Airtable (datos)	Free	USD 0	1.000 registros por base	Al superar los 1.000 leads historicos hay que depurar o pasar a Team.
Slack (aprobaciones)	Free	USD 0	90 dias de historial	El historial viejo se archiva, pero la trazabilidad real vive en Airtable, no en Slack.
TOTAL OPERATIVO		USD 9 a 12 por mes	~1.400 leads/mes	El costo por lead procesado queda en torno a USD 0,008: menos de un centavo por consulta clasificada y respondida.

Matriz de Optimizacion de Costos | Parte 3: palancas aplicadas y ahorro medido

Optimizaciones implementadas en el flujo, con el ahorro verificado en ejecuciones reales

Las tres primeras palancas ya estan aplicadas en el escenario y su efecto se midio comparando ejecuciones antes y despues. Las dos ultimas quedan documentadas como plan de escalado: no se justifican al volumen actual, pero son el siguiente paso cuando el sistema crezca.

PALANCA	QUE HACE	ANTES	DESPUES	AHORRO
Agregador de contexto (aplicado)	El catalogo de Airtable devuelve 5 registros y Make los trataba como 5 paquetes independientes, ejecutando todo el flujo posterior cinco veces. Un modulo Text Aggregator los colapsa en un unico bloque antes de la IA.	18 creditos por lead	7 creditos por lead	61% de creditos. De 55 a 142 leads mensuales dentro del plan Free.
Router que corta temprano (aplicado)	Los leads clasificados como Descartado cierran su ciclo en un solo modulo, sin notificacion ni envio. El spam no consume canal de salida ni tiempo humano de revision.	Todo lead recorria el flujo completo	El descarte termina 3 modulos antes	3 creditos por cada lead basura, y el tiempo de revision que no se gasta.
Trigger por webhook (aplicado)	El disparo ocurre en el instante en que llega el formulario. La alternativa, revisar una casilla cada 15 minutos, consume creditos incluso cuando no hay nada nuevo.	2.880 chequeos vacios al mes	0 ejecuciones sin datos	100% de las ejecuciones en vacio. Ademas baja la latencia a segundos.
Prompt caching (documentado)	El bloque de catalogo, identico en todas las llamadas, se cachea del lado del proveedor y se cobra al 10% en las lecturas siguientes.	800 tokens de entrada por lead	450 nuevos + 350 cacheados	Hasta 90% del costo de entrada. Se activa al superar volúmenes altos y sostenidos.
Batch API (documentado)	Para reprocesos historicos o reportes nocturnos, enviar el lote en modo asincronico a cambio de esperar hasta 24 horas.	Precio estandar	50% del precio estandar	La mitad del costo en toda carga que no sea en vivo.

Conclusion de la matriz

1. La eleccion de modelo se justifica por la tarea, no por la marca. Para clasificar y redactar respuestas cortas con datos ya provistos, el modelo mas barato del mercado hace el trabajo igual de bien que uno 64 veces mas caro, porque el limite de calidad lo pone el prompt y el catalogo, no la capacidad de razonamiento.
2. El costo dominante de este ecosistema no es la IA sino la orquestacion. Optimizar el diseno del escenario rindio 61% de ahorro real; optimizar el modelo hubiera rendido centavos. Por eso la primera pregunta ante una factura alta no es que modelo uso, sino cuantos modulos ejecuta cada corrida y cuantas corridas ocurren sin datos nuevos.
3. Escalar tiene un orden claro: primero activar prompt caching, despues mover los reprocesos a Batch, y recien entonces evaluar un plan superior de Make. Cambiar a un modelo mas caro solo se justifica si aparece una tarea que hoy no existe, como el analisis de documentos densos, y en ese caso conviven los dos modelos, cada uno en su tarea.